Spark基础编程 (II)

摘要

- 基本RDD操作
- 键值对操作
- 数据读取与保存
- 共享变量

摘要

- 基本RDD操作
- 键值对操作
- 数据读取与保存
- 共享变量

基本RDD操作（Transformation操作）

rdd: {1,2,3,3}

函数名	目的	示例	结果
map()	将函数应用于RDD中的每个元素，将返回值构成新的RDD	rdd.map(x => x+1)	{2,3,4,4}
flatMap()	将函数应用于RDD中的每个元素，将返回的迭代器的所有内容构成新的RDD，通常用来切分单词	rdd.flatMap(x => x.to(3))	{1,2,3,2,3,3,3}
filter()	返回一个由通过传给filter()的函数的元素组成的RDD	rdd.filter(x => x!=1)	{2,3,3}
distinct()	去重	rdd.distinct()	{1,2,3}
sample(withReplacement, fraction, [seed])	对RDD采样，以及是否替换	rdd.sample(false, 0.5)	非确定的

基本RDD操作（Transformation操作）

rdd: {1,2,3} 和 other: {3,4,5}

函数名	目的	示例	结果
union()	生成一个包含两个RDD中所有元素的RDD	rdd.union(other)	{1,2,3,3,4,5}
intersection()	求两个RDD共同的元素的RDD	rdd.intersection(other)	{3}
subtract()	移除一个RDD中的内容（例如移除训练数据）	rdd.subtract(other)	{1,2}
cartesian()	与另一个RDD的笛卡尔积	rdd.cartesian(other)	{{1,3},{1,4},{1,5},…{3,5}}

基本RDD操作（Action操作）

rdd: {1,2,3,3}

函数名	目的	示例	结果
collect()	返回RDD中的所有元素	rdd.collect()	{1,2,3,3}
count()	RDD中的元素个数	rdd.count()	4
countByValue()	各元素在RDD中出现的次数	rdd.countByValue()	{(1,1),(2,1),(3,2)}
take(num)	从RDD中返回前num个元素	rdd.take(2)	{1,2}
top(num)	从RDD中返回最"前面"的num个元素（默认降序）	rdd.top(2)	{3,3}
takeOrder(num)(ordering)	从RDD中按照提供的顺序返回最前面的num个元素	rdd.takeOrdered(2)(myOrdering)	{3,3}

基本RDD操作（Action操作）

rdd: {1,2,3,3}

函数名	目的	示例	结果
reduce(func)	并行整合RDD中的所有数据（例如sum）	rdd.reduce((x,y) => x+y)	9
fold(zero)(func)	和reduce一样，但是需要提供初始值	rdd.fold(0)((x,y) => x+y)	9
aggregate(zeroValue)(seqOp, combOp)	和reduce一样，但是通常返回不同类型的函数	rdd.aggregate((0,0))((x,y)=>(x._1+y,x._2+1),(x,y)=>(x._1+y._1,x._2+y._2))	(9,4)
foreach(func)	对RDD中的每个元素使用给定的函数	rdd.foreach(func)	无

摘要

- 基本RDD操作
- 键值对操作
- 数据读取与保存
- 共享变量

键值对操作

- 键值对RDD（Pair RDD）通常用来进行聚合计算
- 键值对RDD的操作接口
- 键值对RDD分区

创建Pair RDD

- 调用map()函数实现
  - Scala

```
val pairs = lines.map(x=>(x.split(" ")(0),x))
```

  - Java

```
PairFunction<String, String, String> keyData = new PairFunction<String, String, String>() {
  public Tuple2<String, String> call(String x){
      return new Tuple2(x.split(" ")[0], x);
  }
}
JavaPairRDD<String, String> pairs = lines.mapToPair(keyData)
```

Pair RDD的Transformation操作

Pair RDD: {(1,2),(3,4),(3,6)}

函数名	目的	示例	结果
reduceByKey(func)	合并具有相同键的值	rdd.reduceByKey((x,y) => x +y)	{(1,2),(3,10)}
groupByKey()	对具有相同键的值进行分组	rdd.groupByKey()	{(1,[2]),(3,[4,6])}
combineByKey(createCombiner, mergeValue, mergeCombiners, partitioner)	使用不同的返回类型合并具有相同键的值		
mapValues(func)	对pair RDD中的每个值应用一个函数而不改变键	rdd.mapValues(x=>x+1)	{(1,3),(3,5),(3,7)}
flatMapValues(func)	对pair RDD中的每个值应用一个返回迭代器的函数，然后对返回的每个元素都生成一个对应原键的键值对记录	rdd.flatMapValues(x=>(x to 5))	{(1,2),(1,3),(1,4),(1,5),(3,4),(3,5)}
keys()	返回一个仅包含键的RDD	rdd.keys()	{1,3,3}
values()	返回一个仅包含值的RDD	rdd.values()	{2,4,6}
sortByKey()	返回一个根据键排序的RDD	rdd.sortByKey()	{(1,2),(3,4),(3,6)}

Pair RDD的Transformation操作

rdd = {(1,2),(3,4),(3,6)} other = {(3,9)}

函数名	目的	示例	结果
subtractByKey(func)	删掉rdd中键与other中的键相同的元素	rdd.subtractByKey(other)	{(1,2)}
join	对两个rdd进行内连接	rdd.join(other)	{(3,(4,9)),(3,(6,9)}
rightOuterJoin	对两个rdd进行连接操作，确保右边rdd的键必须存在（右外连接）	rdd.rightOuterJoin(other)	{(3,(Some(4),9)),(3,(Some(6),9))}
leftOuterJoin	对两个rdd进行连接操作，确保左边rdd的键必须存在（左外连接）	rdd.leftOuterJoin(other)	{(1,(2,none)),(3,(4,Some(9))),(3,(6,Some(9)))}
cogroup	将两个rdd中拥有相同键的数据分组到一起	rdd.cogroup(other)	{(1,([2],[])), (3,([4,6],[9]))}

Pair RDD

- Pair RDD也还是RDD（元素为Java或Scala中的Tuple2对象或者Python中的元组）。Pair RDD支持RDD所支持的函数。例如：
  - Scala

```
result = paris.filter{case (key, value) => value.length <20}
```

  - Java

```
Function<Tuple2<String, String>, Boolean> longWordFilter =
  new Function<Tuple2<String, String>, Boolean>() {
  public Boolean call(Tuple2<String, String> keyValue){
      return (keyValue._2().length() < 20);
   }
}
JavaPairRDD<String, String> result = pairs.filter(longWordFilter);
```

key	value
holden	Likes coffee
panda	Likes long strings and coffee

filter

key	value
holden	Likes coffee

聚合操作

- reduceByKey()　rdd.mapValues(x => (x, 1)).reduceByKey((x, y) => x._1 + y._1, x._2 + y._2))

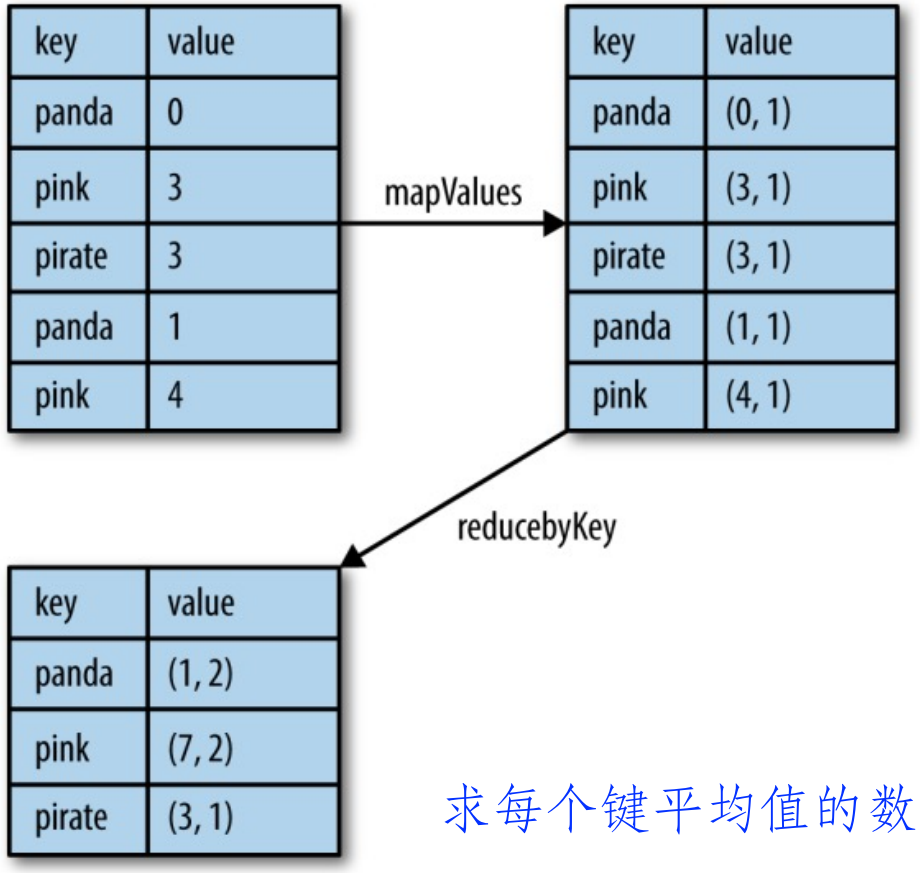

求每个键平均值的数据流

- reduceByKey()　vs. reduce()
  - 两者都能接收一个函数，并使用该函数对值进行合并
  - reduceByKey()会为数据集中的每个键进行并行的归约操作，每个归约操作会将键相同的值合并起来。因为数据集中可能有大量的键，所以reduceByKey()没有被实现为向用户程序返回一个值的行动操作，实际上，它会返回一个由各键和对应键归约出来的结果值组成的新的RDD

聚合操作

- 单词计数

```
val input = sc.textFile("s3://...")
val words = input.flatMap(x => x.split(" "))
val result = words.map(x => (x, 1)).reduceByKey((x, y) => x + y)
```

- 或者

var result = input.flatMap(x=>x.split(“ “)).countByValue()

聚合操作

- combineByKey()：基于键进行聚合的函数

Partition 1

coffee	1
coffee	2
panda	3

Partition 2

coffee	9

```
def createCombiner(value):
  (value, 1)

def mergeValue(acc, value):
  (acc[0] + value, acc[1] +1)

def mergeCombiners(acc1, acc2):
  (acc1[0] + acc2[0], acc1[1] + acc2[1])
```

```
Partition 1 trace:
(coffee, 1) -> new key
accumulators[coffee] = createCombiner(1)
(coffee, 2) -> existing key
accumulators[coffee] = merge Value(accumulators[coffee], 2)
(panda, 3) -> new key
accumulators[panda] = createCombiner(3)

Partition 2 trace:
(coffee, 9) -> new key
accumulators[coffee] = createCombiner(9)

Merge Partitions:
mergeCombiners(partition1.accumulators[coffee],
               partition2.accumulators[coffee])
```

如果是新元素，创建对应累加器的初始值

如果之前遇到过，将该键的累加器对应的当前值与这个新的值进行合并

如果多个分区都有对应于同一个键的累加器，则需要将各个分区的结果进行合并

- 求每个键对应的平均值

```
val result =
  input.combineByKey( (v) =>
  (v, 1),
  (acc: (Int, Int), v) => (acc._1 + v, acc._2 + 1),
  (acc1: (Int, Int), acc2: (Int, Int)) => (acc1._1 + acc2._1, acc1._2 + acc2._2)
  ).map{ case (key, value) => (key, value._1 / value._2.toFloat) }
  result.collectAsMap().map(println(_))
```

分组

- groupByKey()：对数据进行分组
  - RDD: [K, V] → [K, Iterable[V]]
    - rdd.reduceByKey(func)与rdd.groupByKey().mapValues(value => value.reduce(func))等价，但前者更为高效。
- cogroup()：对多个共享同一个键的RDD进行分组
  - RDD: [K, V] & [K, W] → [(K, (Iterable[V], Iterable[W]))]
  - 不仅可以用于实现连接操作，还可以用来求键的交集。除此之外，还能同时应用于三个及以上的RDD。

连接

- 将有键的数据与另一组有键的数据一起使用。
- 连接方式：右外连接，左外连接，交叉连接，内连接。
  - 内连接(join)：只有两个pair RDD都存在的键才输出。
  - 左外连接(leftOuterJoin)：源RDD的每个键都有对应的记录。每个键相应的值是由一个源RDD中的值与一个包含第二个RDD的值的Option对象组成的二元组。
  - 右外连接(rightOuterJoin)：预期结果中的键必须出现在第二个RDD中，二元组中可缺失的部分则来自于源RDD而非第二个RDD。

排序

- sortByKey()：默认升序
- 自定义排序
  - Scala

```
val input: RDD[(Int, Venue)] = ...
implicit val sortIntegersByString = new Ordering[Int]{
    override def compare(a: Int, b: Int) =a.toString.compare(b.toString)}
```

  - Java

```
class IntegerComparator implements Comparator<Integer>{
   public int compare(Integer a, Integer b) {
      return String.valueOf(a).compareTo(String.valueOf(b));
    }
}
```

Pair RDD的Action操作

RDD = {(1,2),(3,4),(3,6)}

函数名	目的	示例	结果
countByKey()	对每个键对应的元素进行计数	rdd.countByKey()	{(1,1),(3,2)}
collectAsMap()	将结果以映射表的形式返回，以便查询	rdd.collectAsMap()	Map{(1,2),(3,6)}
lookup(key)	返回给定键对应的所有值	rdd.lookup(3)	[4,6]

collectAsMap() 作用于K-V类型的RDD上，作用与collect不同的是collectAsMap函数不包含重复的key，对于重复的key，后面的元素覆盖前面的元素。

数据分区

- 合理分布数据能减少网络通信，从而大大提高性能。
- Spark可以选择自己的RDD分区分布来降低通信，但只有当一个数据集重复多次使用键值操作才起作用。
- Spark的分区操作作用于key/value型RDD上，它会让系统根据键值函数来分组元素。
  - 比如限定一组键值出现在指定节点上

数据分区

- 用户信息的大表(UserID, UserInfo)
- 过去五分钟的网站链接点击信息(UserID, LinkInfo)
- 计算多少用户访问了不在订阅列表的链接：用Spark的join()来分组UserInfo和LinkInfo，基于每个UserID。

```
// Initialization code; we load the user info from a Hadoop SequenceFile on HDFS.
// This distributes elements of userData by the HDFS block where they are found,
// and doesn't provide Spark with any way of knowing in which partition a
// particular UserID is located.
val sc = new SparkContext(...)
val userData = sc.sequenceFile[UserID, UserInfo]("hdfs://...").persist()

// Function called periodically to process a logfile of events in the past 5 minutes;
// we assume that this is a SequenceFile containing (UserID, LinkInfo) pairs.
def processNewLogs(logFileName: String) {
  val events = sc.sequenceFile[UserID, LinkInfo](logFileName)
  val joined = userData.join(events)// RDD of (UserID, (UserInfo, LinkInfo)) pairs
  val offTopicVisits = joined.filter {
    case (userId, (userInfo, linkInfo)) => // Expand the tuple into its components
      !userInfo.topics.contains(linkInfo.topic)
  }.count()
  println("Number of visits to non-subscribed topics: " + offTopicVisits)
}
```

数据分区

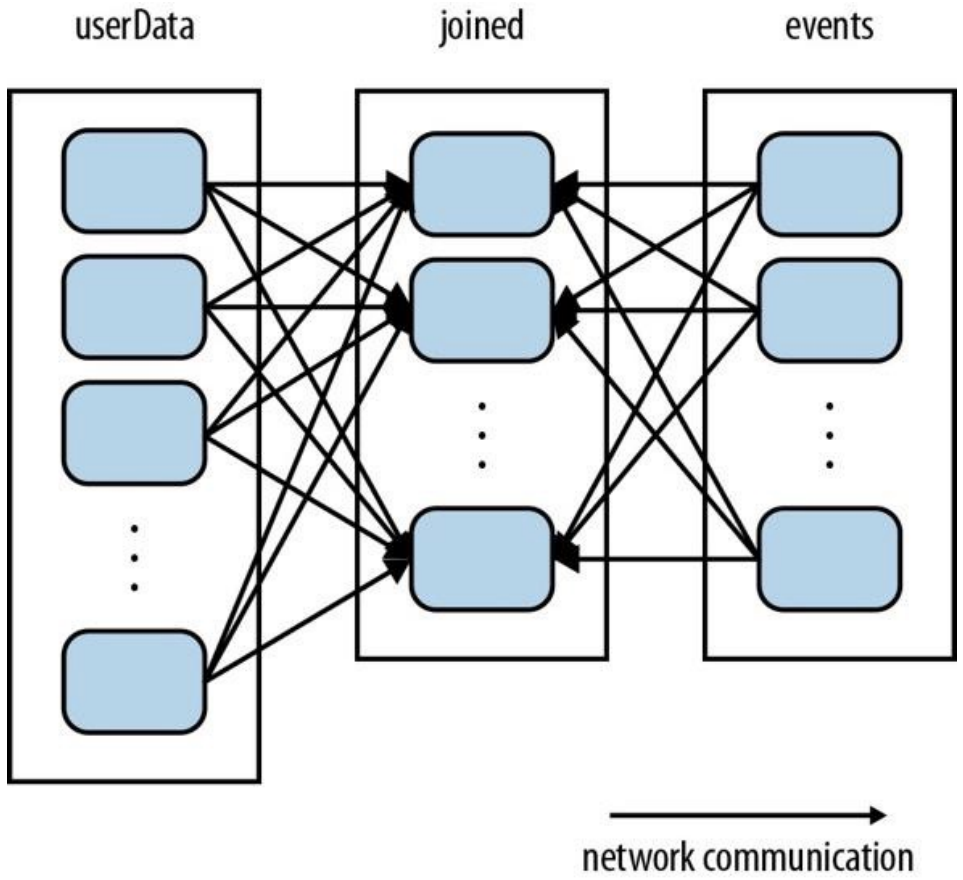

- 每次调用processNewLogs()就会调用join()，在不知道该键值数据分区的情况下。默认情况下，会先哈希两个数据集的所有键，然后通过网络发送相同哈希值的元素到同一台机器，然后再用join连接相同机器上相同键值的元素
- userData表比五分钟日志事件文件大得多，这会浪费大量的计算：在每次调用时，userData表都会被散列并通过网络传输，即使它并没有改变。

数据分区


```
val sc = new SparkContext(...)
val userData = sc.sequenceFile[UserID, UserInfo]("hdfs://...")
                 .partitionBy(new HashPartitioner(100))    // Create 100 partitions
                 .persist()
```

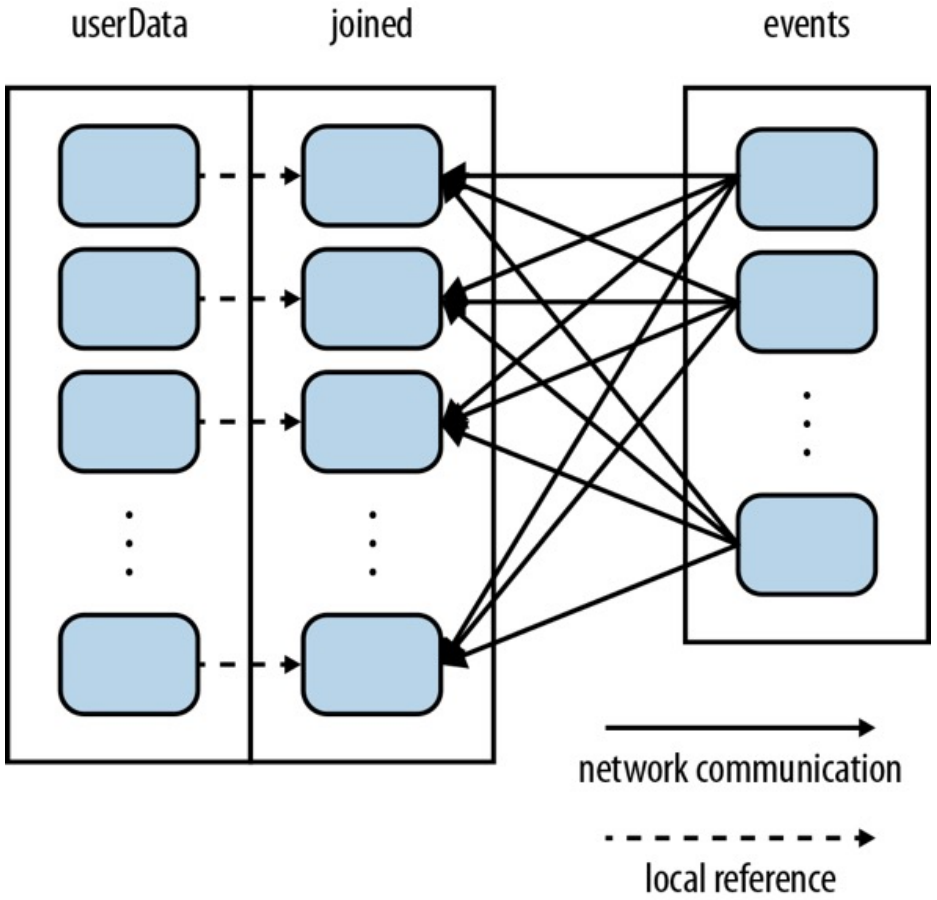

对userData表使用partitionBy()，将其转为哈希分区

- 调用partitionBy()建立用户数据的时候，Spark知道这是哈希分区，调用join()方法时候利用这个优势。特别是，当我们调用userData.join(events)，Spark将重排事件RDD，把每个特定UserID发送到包含userData的散列分区，其结果是，减少了许多网络通信，让程序更快地运行。

数据分区

- partitionBy()是一个变换，所以它总是返回一个新的RDD。它不改变原来的RDD。RDD创建后无法修改。因此保存partitionBy()的结果userData非常重要的，而不是原来sequenceFile()。
- 在RDD传递给partitionBy()之后如果没有保存RDD，将导致RDD的后续使用重做数据分区操作。如果没有持久保存数据，分区的RDD会导致RDD完整谱系（lineage）的重新计算。那会与partitionBy()的优点矛盾，导致重复分区，并且通过网络重混数据（shuffling），相当于没有指定分区的情况。
- Spark的其它操作也常常自动生成已知划分信息的RDD，除了join()其他许多操作都会利用这一信息。例如，sortByKey()和groupByKey()会生成范围分区和哈希散列分区的RDD。而另一方面，像map()的操作会生成新的RDD并丢失父分区的信息，因为这个操作理论上可以修改每个记录。

数据分区


```
scala> val pairs = sc.parallelize(List((1, 1), (2, 2), (3, 3)))
pairs: spark.RDD[(Int, Int)] = ParallelCollectionRDD[0] at parallelize at <console>:12

scala> pairs.partitioner
res0: Option[spark.Partitioner] = None

scala> val partitioned = pairs.partitionBy(new spark.HashPartitioner(2))
partitioned: spark.RDD[(Int, Int)] = ShuffledRDD[1] at partitionBy at
<console>:14

scala> partitioned.partitioner
res1: Option[spark.Partitioner] = Some(spark.HashPartitioner@5147788d)
```

如果想在进一步的操作中使用分区，应该在输入第三行加上persist()，并在其中定义分区。如果没有persist()，随后RDD将重新评估分区的整个属性，这将导致数据对一遍又一遍地作哈希分区操作。

数据分区

- 以下操作会使输出RDD设置好分区器：cogroup(), groupWith(), join(), leftOuterJoin(), rightOuterJoin(), groupByKey(), reduceByKey(), combineByKey(), partitionBy(), sort(), mapValues()（如果父RDD具有分区器），flatMapValues()（如果父RDD具有分区器），和filter()（如果父RDD具有分区器）。其他所有操作将产生的结果都没有分区器。
- 对于多RDD操作，其分区器被设置的规则取决于父RDDs的分区器。默认情况下是散列分区器，分区数目与并发级别保持一致。然而，如果其中一个父RDD含有分区器，结果便会采用这个分区方式；如果多个父RDD都含有分区器，结果将取第一个父分区的分区器。

Example： PageRank

- 数据集：(pageID, linkList)
- 输出： (pageID, rank)
- 算法：
  - 将每个页面的排序值初始化为1.0；
  - 在每次迭代中，对页面p，向其每个相邻页面（有直接链接的页面）发送一个值为rank(p)/numNeighbours(p)的贡献值；
  - 将每个页面的排序值设为0.15+0.85*contributionsReceived
  - 重复后两步，算法逐渐收敛。通常需要10轮迭代。

Example： PageRank


```scala
// Assume that our neighbor list was saved as a Spark objectFile
val links = sc.objectFile[(String, Seq[String])]("links")
             .partitionBy(new HashPartitioner(100))
             .persist()

// Initialize each page's rank to 1.0; since we use mapValues, the resulting RDD
// will have the same partitioner as links
var ranks = links.mapValues(v => 1.0)

// Run 10 iterations of PageRank
for (i <- 0 until 10) {
  val contributions = links.join(ranks).flatMap {
    case (pageId, (links, rank)) =>
      links.map(dest => (dest, rank / links.size))
  }
  ranks = contributions.reduceByKey((x, y) => x + y).mapValues(v => 0.15 + 0.85*v)
}

//Write out the final ranks
ranks.saveAsTextFile("ranks")
```

为了最大化分区相关优化的潜在作用，应该在无需改变元素的键时尽量使用mapValues()或flatMapValues()

自定义分区

- HashPartitioner和RangePartitioner
- 继承org.apache.spark.Partitioner
  - numPartitions: Int 返回创建出来的分区数
  - getPartition(key: Any): Int 返回给定键的分区编号
  - equals(): Boolean 检查分区器对象是否和其它分区器实例相同。

自定义分区


```
class DomainNamePartitioner(numParts: Int) extends Partitioner{
    override def numPartitions: Int = numParts
    override def getPartition(key: Any): Int = {
      val domain = new Java.net.URL(key.toString).getHost()
      val code = (domain.hashCode % numPartitions)
      if (code<0){  code + numPartitions } else { code }
    }
    override def equals(other:Any): Boolean = other match {
       case dnp: DomainNamePartitioner  =>
              dnp.numPartitions == numPartitions
       case _ => false
    }
}
```

摘要

- 基本RDD操作
- 键值对操作
- 数据读取与保存
- 共享变量

数据源

- 文件格式与文件系统
- Spark SQL中的结构化数据源
- 数据库与键值存储

文件格式

格式名称	结构化	备注
文本文件	否	普通的文本文件，每行一条记录
JSON	半结构化	常见的基于文本的格式，半结构化；大多数库都要求每行一条记录
CSV	是	非常常见的基于文本的格式，通常在电子表格应用中使用
SequenceFiles	是	一种用于键值对数据的常见Hadoop文件格式
Protocol buffers	是	一种快速、节约空间的跨语言格式
对象文件	是	用来将Spark作业中的数据存储下来以让共享的代码读取。改变类的时候它会失效，因为它依赖于Java序列化。

文件格式

- 文本文件：输入的每一行都会成为RDD的一个元素；也可以将多个完整的文本文件一次性读取为一个Pair RDD，键是文件名，值是文件内容。

scala

```
val input = sc.textFile("file:///home/spark/README.MD")
input.saveAsTextFile(outputFile)
val input = sc.wholeTextFiles("file:///home/spark/salefiles")
```

- JSON：将数据作为文本文件读取，然后使用JSON解析器来对RDD的值进行映射操作。

python

```
import json
data = input.map(lambda x: json.loads(x))
(data.filter(lambda x: x["lovesPandas"]).map(lambda x: json.dumps(x)).saveAsTextFile(outputFile))
```

文件格式

- CSV：当作普通文本文件读取，再对数据进行处理。每条记录都没有相关联的字段名，只能得到对应的序号。常规做法是使用第一行中每列的值作为字段名。

```
import Java.io.StringReader
Import au.com.bytecode.opencsv.CSVReader
…
val input = sc.textFile(inputFile)
val result = input.map{ line =>
        val reader = new CSVReader(new StringReader(line));
        reader.readNext();
    }
```

文件格式

- SequenceFile：由没有相对关系结构的键值对文件组成的常用Hadoop格式。有同步标记，Spark可以用它来定位到文件中的某个点，然后再与记录的边界对齐。由实现Hadoop的Writable接口的元素组成。

```
val data = sc.sequenceFile(inFile, classOf[Text], classOf[IntWritable]).map{case(x,y) => (x.toString, y.get()}
val data = sc.parallelize(list(("Panda", 3), ("Kay", 6), ("Snail", 2)))
data.saveAsSequenceFile(outputFile)
```

文件系统

- 本地“常规”文件系统
  - file:///home/holden/happypandas.gz
- Amazon S3
  - s3n://bucket/path-within-bucket
- HDFS
  - hdfs://master:port/path

Spark SQL中的结构化数据

- Hive： Spark SQL可以读取Hive支持的任何表

```
import org.apache.spark.sql.hive.HiveContext
val hiveCtx = new org.apache.spark.sql.hive.HiveContext(sc)
val rows = hiveCtx.sql("SELECT name, age FROM users")
val firstRow = rows.first()
println(firstRow.getString(0))
```

Spark SQL中的结构化数据

- JSON：Spark SQL可以自动推断出JSON数据的结构信息

```
import org.apache.spark.sql.hive.HiveContext
val hiveCtx = new org.apache.spark.sql.hive.HiveContext(sc)
val tweets = hiveCtx.jsonFile("tweets.json")
tweets.registerTempTable("tweets")
val results = hiveCtx.sql("SELECT user.name, text FROM tweets")
```

数据库

- Java数据库连接： org.apache.spark.rdd.JdbcRDD

```
def createConnection() = {
  Class.forName("com.mysql.jdbc.Driver").newInstance();
  DriverManager.getConnection("jdbc:mysql://localhost/test?user=holden");
}
def extractValues(r: ResultSet) = {
  (r.getInt(1), r.getString(2))
}
val data = new JdbcRDD(sc, createConnection, "SELECT * FROM panda
   WHERE ? <= id and id <= ?", lowerBound = 1, upperBound = 3, numPartitions = 2, mapRow =
extractValues)
println(data.collect().toList)
```

数据库

- Spark可以通过Hadoop输入格式访问HBase，这个输入格式会返回键值对数据，其中键的类型为org.apache.hadoop.hbase.io.ImmutableBytesWritable，值的类型为org.apache.hadoop.hbase.client.Result.

摘要

- 基本RDD操作
- 键值对操作
- 数据读取与保存
- 共享变量

共享变量

- 在默认情况下，当Spark在集群的多个不同节点的多个任务上并行运行一个函数时，它会把函数中涉及到的每个变量，在每个任务上都生成一个副本。但是，有时候，需要在多个任务之间共享变量，或者在任务（Task）和任务控制节点（Driver Program）之间共享变量。为了满足这种需求，Spark提供了两种类型的变量：广播变量（broadcast variables）和累加器（accumulators）。广播变量用来把变量在所有节点的内存之间进行共享。累加器则支持在所有不同节点之间进行累加计算（比如计数或者求和）。

共享变量

- 广播变量
  - 让程序高效地向所有工作节点发送一个较大的只读值，以供一个或多个Spark操作使用。
- 累加器
  - 支持在所有不同节点之间进行累加计算（比如计数或者求和）

广播变量

- 可以通过调用SparkContext.broadcast(v)来从一个普通变量v中创建一个广播变量。这个广播变量就是对普通变量v的一个包装器，通过调用value方法就可以获得这个广播变量的值，例如：

```
scala> val broadcastVar = sc.broadcast(Array(1, 2, 3))
broadcastVar: org.apache.spark.broadcast.Broadcast[Array[Int]] = Broadcast(0)
scala> broadcastVar.value
res0: Array[Int] = Array(1, 2, 3)
```

这个广播变量被创建以后，那么在集群中的任何函数中，都应该使用广播变量broadcastVar的值，而不是使用v的值，这样就不会把v重复分发到这些节点上。此外，一旦广播变量创建后，普通变量v的值就不能再发生修改，从而确保所有节点都获得这个广播变量的相同的值。

累加器

- 累加器是仅仅被相关操作累加的变量，通常可以被用来实现计数器（counter）和求和（sum）。Spark原生地支持数值型（numeric）的累加器，程序开发人员可以编写对新类型的支持。
- 一个数值型的累加器，可以通过调用SparkContext.longAccumulator()或者SparkContext.doubleAccumulator()来创建。运行在集群中的任务，就可以使用add方法来把数值累加到累加器上，但是，这些任务只能做累加操作，不能读取累加器的值，只有任务控制节点（Driver Program）可以使用value来读取累加器的值。

累加器

- 例如：

```
scala> val accum = sc.longAccumulator("My Accumulator")
accum: org.apache.spark.util.LongAccumulator = LongAccumulator(id: 0, name: Some(My Accumulator), value: 0)
scala> sc.parallelize(Array(1, 2, 3, 4)).foreach(x => accum.add(x))
scala> accum.value
res1: Long = 10
```

THANK YOU

南京大学
NANJING UNIVERSITY

南京大学计算机软件研究所
Institute of Computer Software, Nanjing University